خصص

Kass Layer

طبقة مصطلحات عربية فوق معاجم سوار

من لغة الكاتب إلى المصطلح المعتمد

طبقة تقرأ النص الذي يكتبه غير المتخصص، وتقترح لكل لفظ دخيل أو عامي أو عام المصطلحَ المعتمد في معاجم سوار، ويبقى القرار للمستخدم.

عرض تقني · نوفمبر 2026 · فرع enrichment-pass1

مجمع الملك سلمان العالمي للغة العربية
King Salman Global Academy for Arabic Language

الكاتب غير المتخصص يكتب بلغته، لا بلغة المعجم

ما يُكتب	المعتمد في سوار	
المودل	نموذج ←	تعريب
الداتا	بيانات ←	تعريب
LLM	نموذج لغوي كبير ←	اختصار إنجليزي
سولار بانلز	ألواح كهروضوئية ←	إنجليزي بحروف عربية
عميل ذكي	وكيل ذكي ←	كلمة عربية عامة

لماذا هي مشكلة؟

- المعاجم المتخصصة موجودة ومعتمدة، لكن الكاتب لا يعرف المصطلح أو لا يجده وقت الكتابة
- النص الناتج يخلط بين التعريب والإنجليزية والعامية، فيضعف توحيد المصطلح
- المدقق الإملائي والنحوي لا يعرف أن «المودل» له مقابل معتمد

الأصعب: الكلمة العربية العادية التي لها معنى تخصصي في سياق ومعنى عام في غيره. «عميل» في نص عن الذكاء الاصطناعي وكيل، وفي «وقّع العميل العقد» زبون.

الهدف: اقتراح المصطلح المعتمد بدقة، والقرار للمستخدم

22
معجمًا متخصصًا من سوار

40,102
مصطلح بتعريفه ومقابله الإنجليزي

6
مجالات في الواجهة

87,399
صيغة بديلة مراجَعة

1
المصطلح من سوار فقط
لا يُخترع مصطلح ولا يُقترح لفظ ليس في معجم معتمد.

2
اقتراح لا استبدال
النص لا يتغير إلا باختيار المستخدم، كلمةً كلمة.

3
لكل اقتراح سبب ومصدر
المعجم، المقابل الإنجليزي، التعريف، وسبب الحاجة للتدقيق.

4
الدقة قبل التغطية
ما لا نثق به يُعرض للتدقيق أو يُحذف، ولا يُطبَّق آليًّا.

الإثراء: ماذا يكتب الناس بدل كل مصطلح؟

خمس مراحل تُنفَّذ مرة واحدة قبل التشغيل، وكل ما تقترحه النماذج يراجَع قبل أن يدخل الفهرس

1 سوار

40,102

مصطلح في 22 معجمًا؛ الملفات الأصلية لا تُعدَّل

2 توليد الصيغ

87,399 صيغة

Qwen3.5-4B يولّد البدائل لكل مصطلح

3 مراجعة Claude

100%

روجعت المعاني كلها؛ 50,621 صيغة مؤكدة و36,778 مشروطة بالسياق

4 صيغ عربية وتدقيق

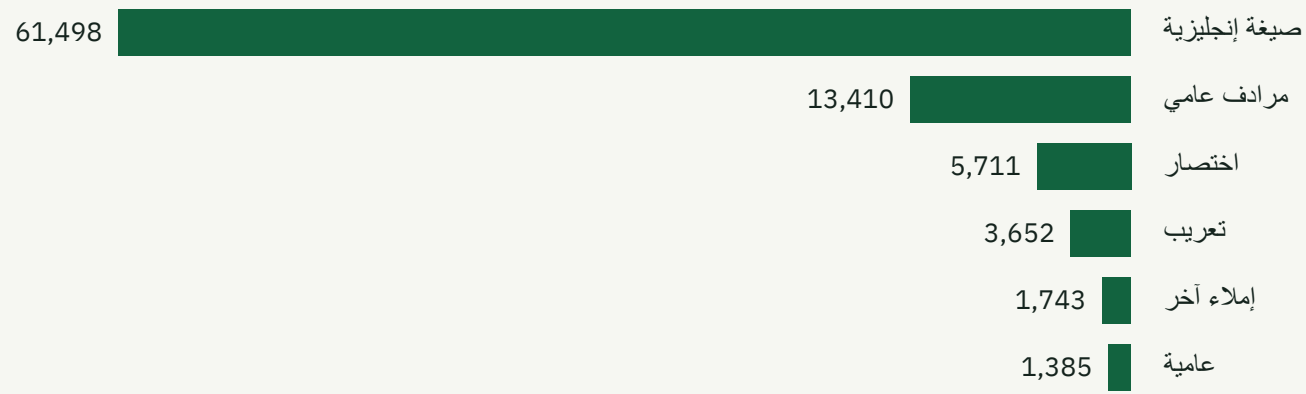
825 رابطًا سُحب

Gemma 3 12B يقترح ويصنّف العلاقة، وClaude يقرر

5 الاستعمال الحقيقي

≈360 صيغة

ويكي بيانات وويكيبيديا، مفلترة بـ 20 GB تغريدات

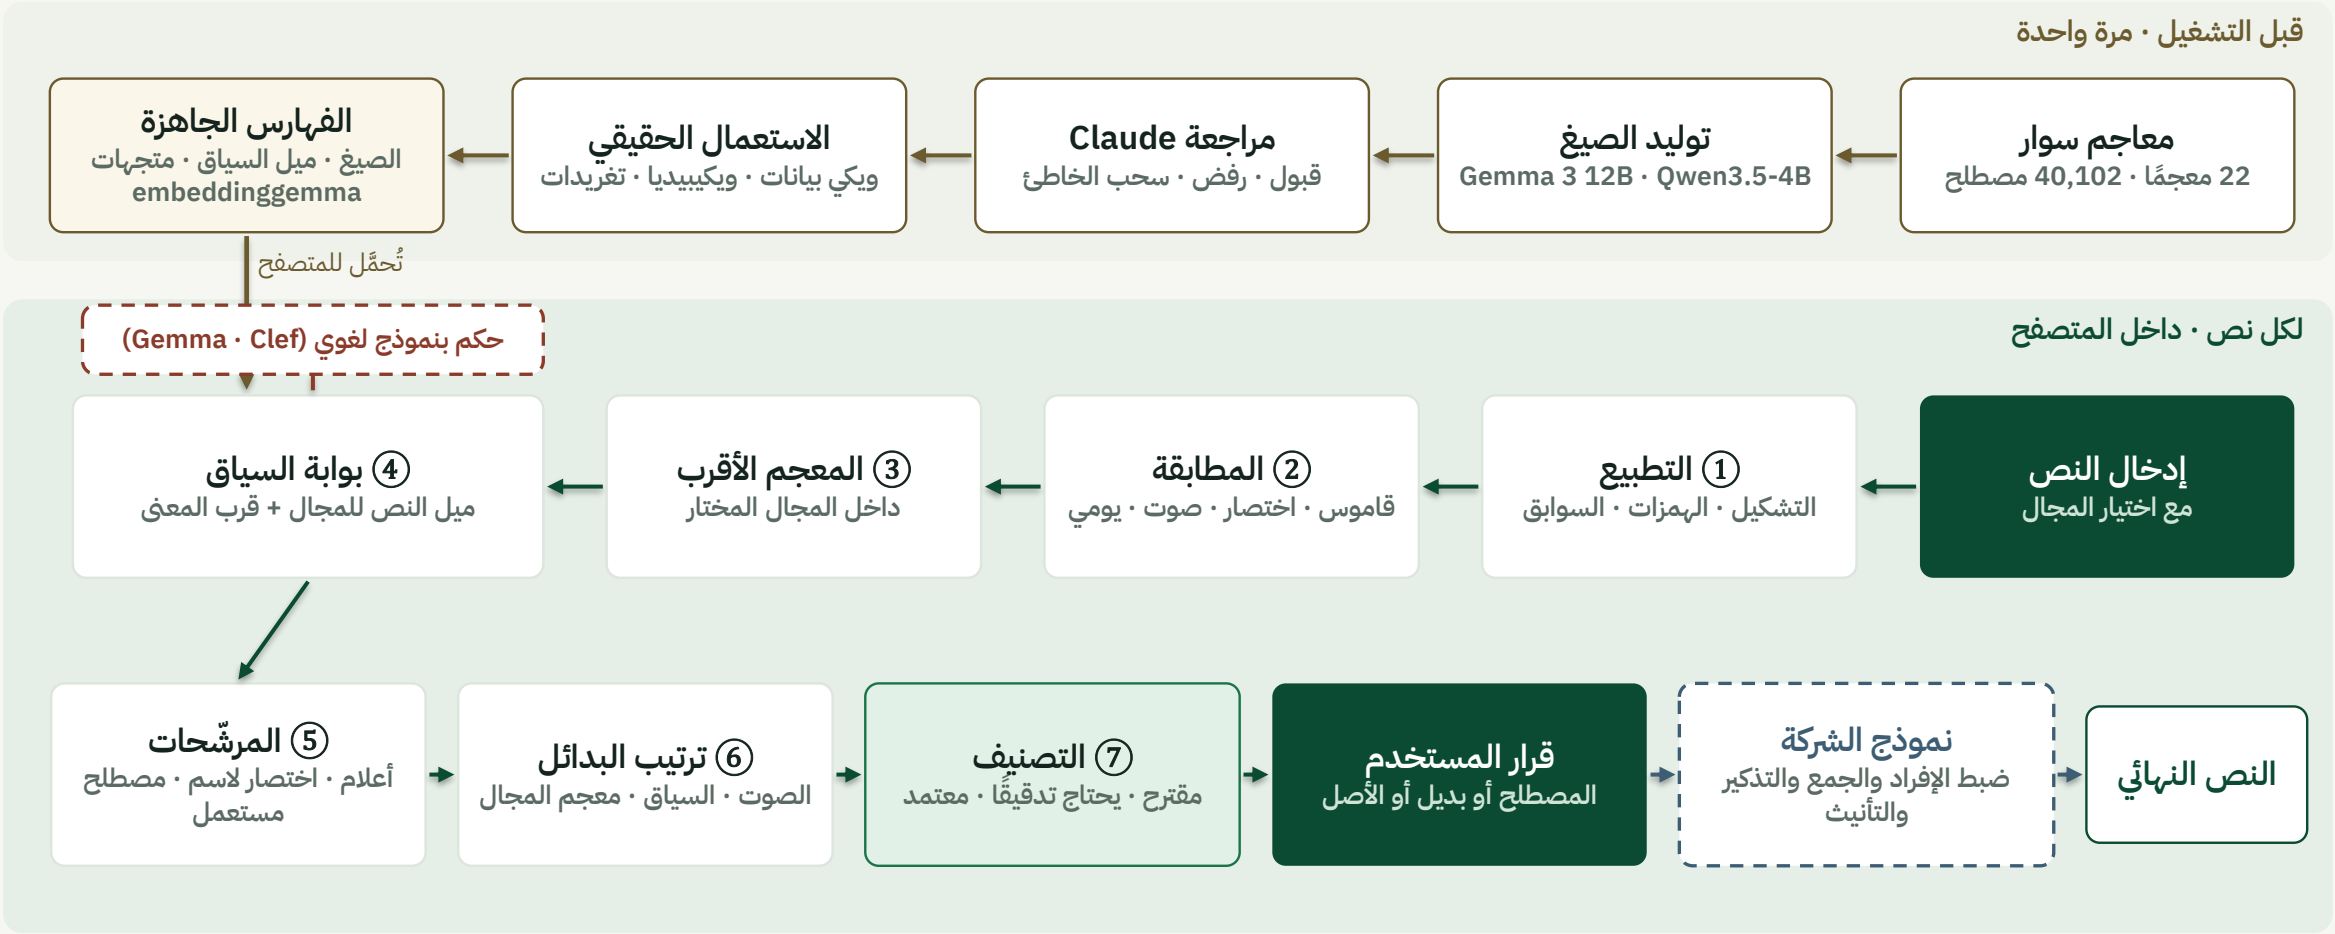


أنواع الصيغ البديلة

أكثرها صيغ إنجليزية (Model، Dataset)، ثم المرادفات العامية والاختصارات.

الصيغة «المشروطة» لا تُقترح إلا إذا أيّدها سياق النص.

رحلة النص: من الإدخال إلى قرار المستخدم



الكاشف نسختان متطابقتان: JavaScript في المتصفح وPython في الخادم (212 من 212 جملة)

جُرِّب ولم يُعتمد

مخطط له

منفَّذ ويعمل

مثال حقيقي من الكاشف، كما يراه المستخدم

النص المُدخل · مجال تقني

بنينا عميل ذكي يستخدم المودل والـ LLM لتحليل البيانات

مقترح | يحتاج تدقيقًا | مصطلح معتمد

المودل	نموذج	تعريب له مصطلح واحد في معجم البيانات والذكاء الاصطناعي (Model)
LLM	نموذج لغوي كبير	اختصار إنجليزي (Large Language Model)
عميل ذكي	وكيل ذكي	كلمة عامة لها مصطلح تخصصي في هذا السياق
لتحليل البيانات	—	مصطلح معتمد أصلًا، لا يُقترح له شيء

بطاقة الاقتراح في الواجهة

عميل ذكي ← وكيل ذكي

يحتاج تدقيقًا

المعجم: معجم البيانات والذكاء الاصطناعي

بالإنجليزية: Intelligent Agent (IA)

التعريف: كيان ذاتي التحكم يدرك بيئته ويقوم بأفعال لتحقيق أهداف محددة.

السبب: كلمة عامة لها مصطلح تخصصي في هذا السياق

وكيل ذكي | الكلمة الأصلية

قواعد الدقة: ما الذي يمنع الكاشف من الخطأ؟

كل قاعدة أُضيفت بعد خطأ حقيقي رُصد في مقالات أو تغريدات، ولم تُعتمد إلا إذا لم تسُؤ الاختبارات

بوابة السياق

الكلمة اليومية لا تُقترح إلا إذا مال النص إلى المجال وقرب المعنى من الكلمات حولها

يمنع: «مقدم الطلب» لا تصبح «مذيع»

الكلمة الشائعة جدًّا

الكلمة المفردة الشائعة في المقالات العامة لا تُقترح

يمنع: معالجة، الضغط

الصيغ العربية للتدقيق

المرادف والإملاء الآخر يُعرضان للتدقيق لا للاستبدال

يمنع: سهم ممتاز = اختيار جيد

الاختصار بين قوسين

يُحذف إذا كان اختصارًا لاسم مكتوب قبله

يمنع: بورصة الدار البيضاء (CSE)

أسماء الأعلام اللاتينية

كلمة لاتينية مجاورة لكلمة لاتينية بحرف كبير

يمنع: Maroc Telecom

الكاتب يستعمل المصطلح

لا يُقترح «وكيل» لـ«العميل» في نص يكرر «الوكيل» للمعنى الآخر

يمنع: سيطرح الوكيل أسئلة على العميل

التقنيات: ما يعمل فعلًا، وما جُرِّب، وما هو مخطط

مستخدم فعليًّا

التشغيل

- الكاشف بـ JavaScript داخل المتصفح
- محرك Python مطابق + FastAPI
- فهارس JSON ومتجهات embeddinggemma محسوبة مسبقًا
- حاوية Podman على خادم الأكاديمية (معالج فقط)

البناء

- Qwen3.5-4B لتوليد الصيغ
- Gemma 3 12B عبر Ollama (RTX 3080)
- Claude: المراجعة والبرمجة والاختبار
- ويكي بيانات، ويكيبيديا، 20 GB تغريدات

تجريبي: جُرِّب ولم يُعتمد

حكم السياق

- Clef-Flash: دقة 59.7%
- Gemma 3 12B حكمًا: دقة 61.5%
- Jev: نموذج مغلق، لا مفتاح، لم يُجرَّب

التضمين والتصنيف

- bge-m3 · e5-large · Qwen3-Embedding · embeddinggemma: AUC من 0.55 إلى 0.67
- مصنّف على سمات الكاشف: AUC بين 0.46 و0.48 خارج نوع النص

مخطط له

قريبًا

- نموذج الشركة لضبط الإفراد والجمع والتذكير والتأنيث بعد إدراج المصطلح
- فحص 1,041 رابطًا يوميًّا بجمل حقيقية (جارٍ)

لاحقًا

- إثراء «وكيل» و67 مصطلحًا بلا اسم إنجليزي
- حكم سياق خفيف يعمل على المعالج (بحث)

كيف قِسنا: أربع مجموعات اختبار وقاعدة قبول صارمة

212

جملة في 6 ملفات اختبار

ضبط، اختبار مستقل، غموض، كلمات عربية

31

مقطعًا من مقالات منشورة

3 دفعات؛ الأخيرة حُكم عليها قبل أي تعديل

310

تغريدات حقيقية

صيغة مضافة واحدة في كل تغريدة

368

اقتراحًا محكومًا عليه

مجمّعة من كل المجموعات لتحليل الأخطاء

قاعدة القبول

- لا يُعتمد أي تعديل إذا ساءت نتيجة أي ملف من الملفات الستة
- تطابق المحرك والصفحة: 212 من 212 جملة، و38 اختبارًا برمجيًّا ناجحًا
- كل قرار مسجّل في reports/pc_decisions.md

المقاييس

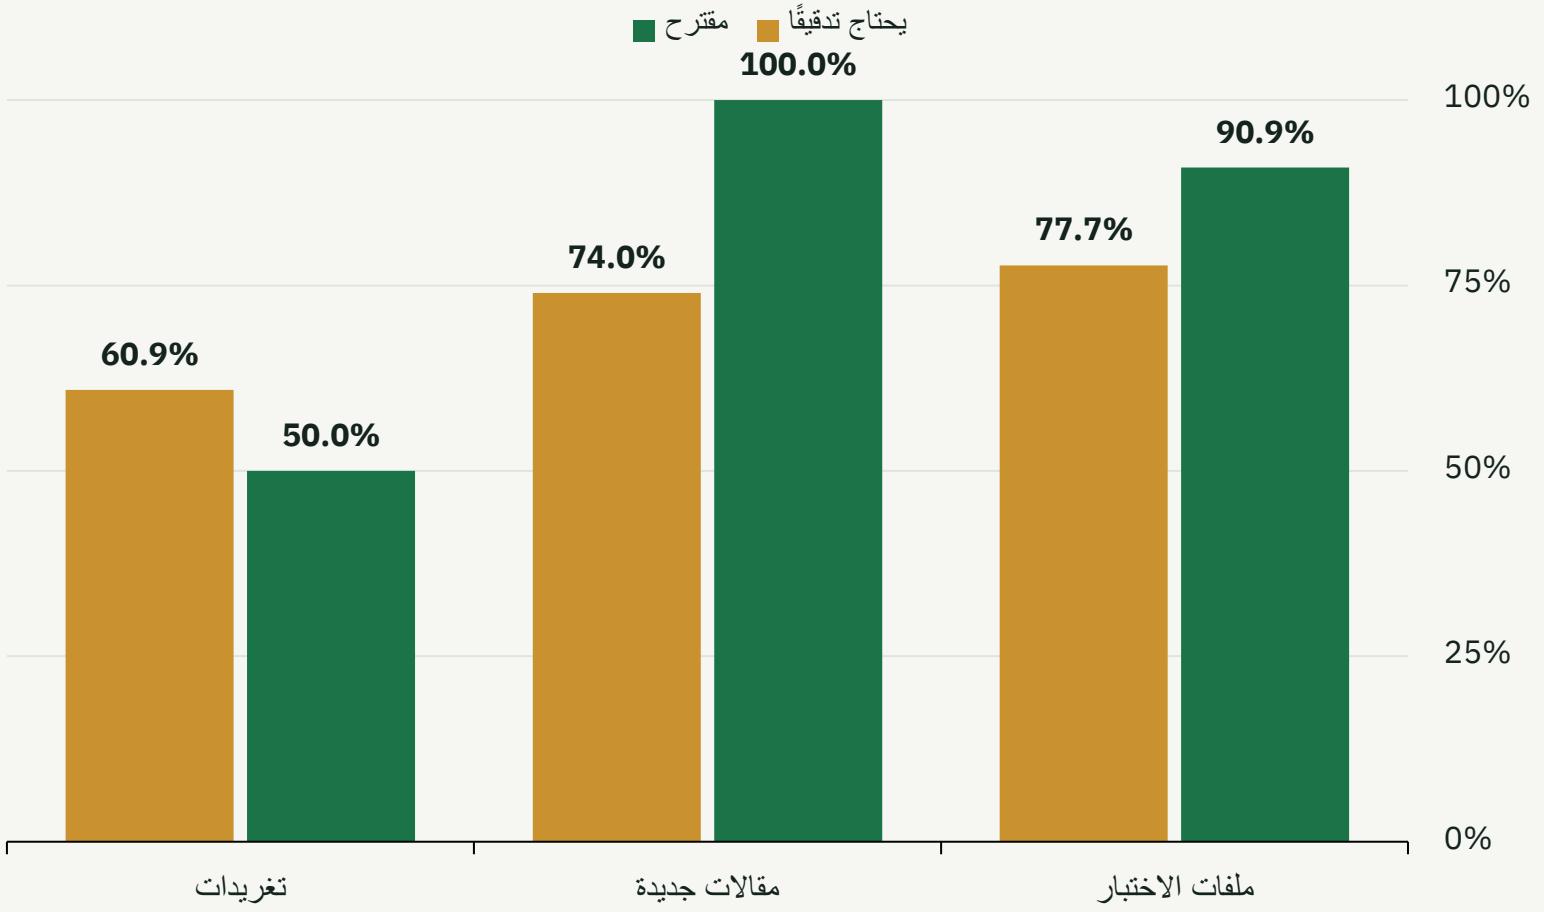
- **الدقة:** من الاقتراحات المعروضة، كم منها صحيح؟
- **الاستدعاء:** من الكلمات المطلوب استبدالها، كم اكتُشف؟
- **الدقة لكل طبقة:** «مقترح» و«يحتاج تدقيقًا» كلٌّ على حدة

النتيجة: الاستبدالات المؤكدة موثوقة، والكلمات اليومية هي الفجوة

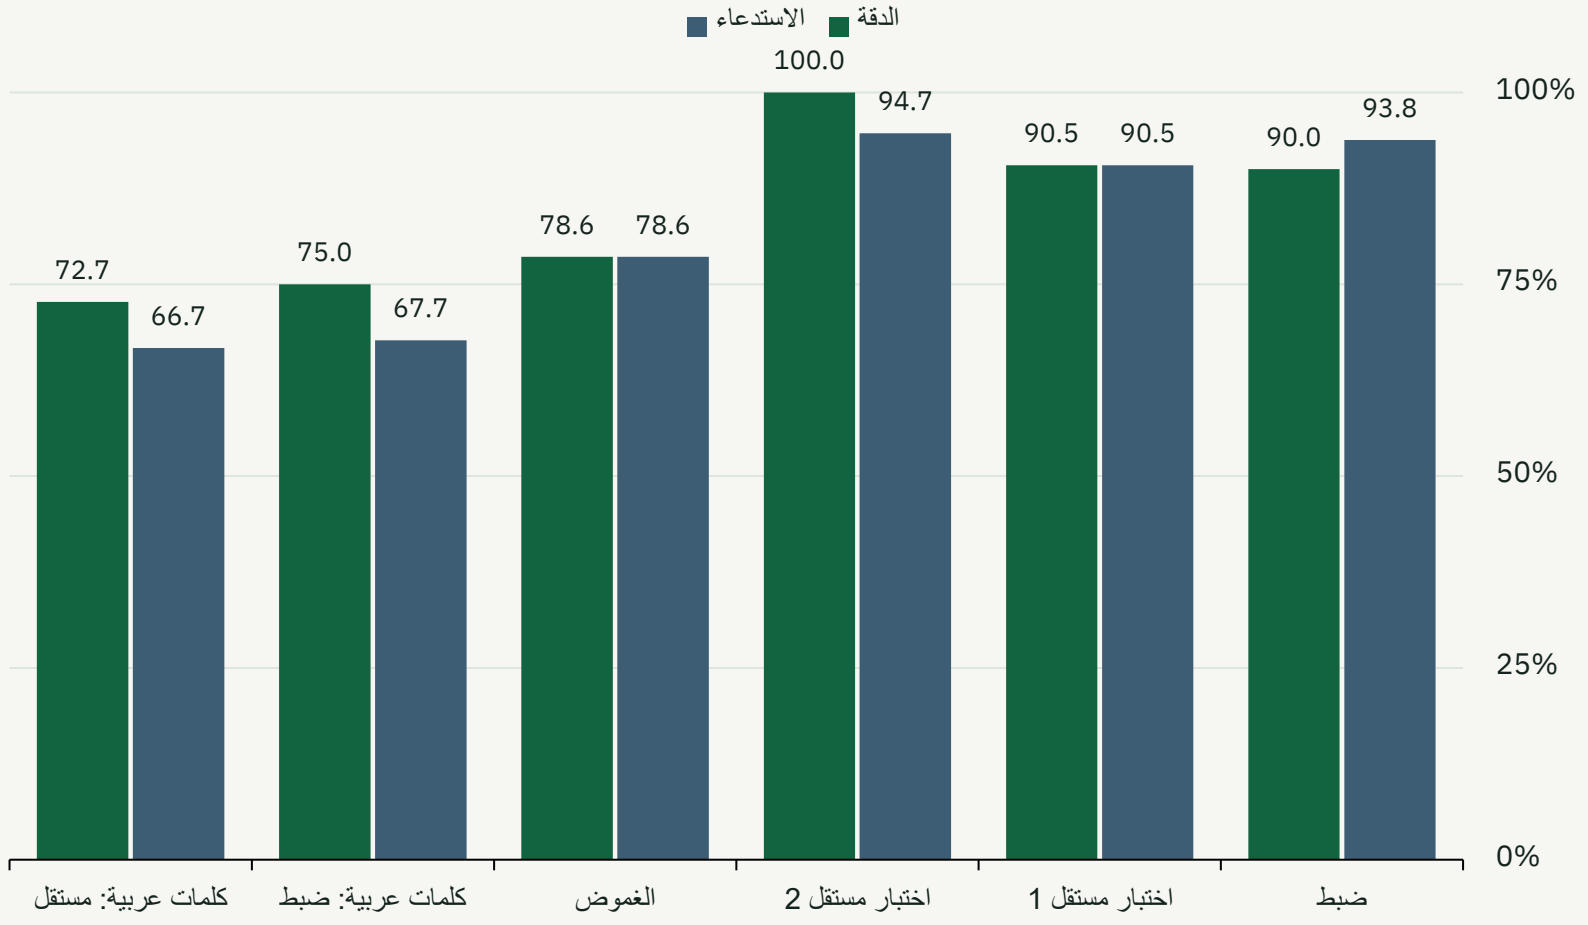
كيف تُقرأ

- **مقترح** = ما يطبّقه «تطبيق الكل»: 50 من 55 في ملفات الاختبار، و15 من 15 في دفعتين جديدتين.
- **يحتاج تدقيقًا** = كلمات عربية يقرر فيها المستخدم: 74% في المقالات الجديدة (37 من 50).
- **التغريدات** اختبار قاسٍ عمدًا: جمل قصيرة بلا سياق، و10 اقتراحات «مقترحة» فقط.

الأحكام من Claude، ومراجعة مستقلة لعينة من 50 حكمًا جارية.



ملفات الاختبار الستة: الاستدعاء والدقة اليوم



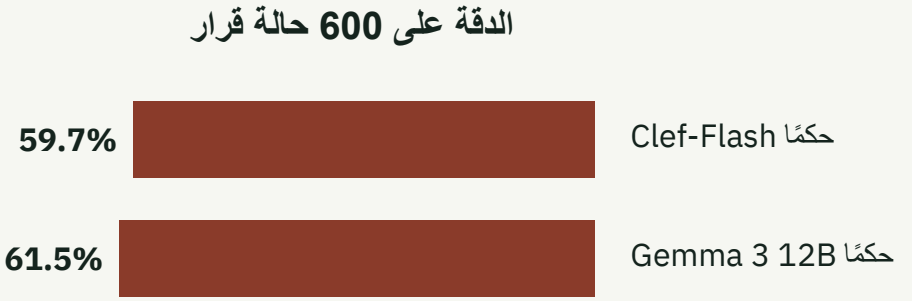
ما وراء الأرقام

- الإنجليزية والتعريب: استدعاء ودقة حول 90% فأعلى
- الكلمات العربية اليومية: استدعاء نحو 67%، والسبب أن بوابة السياق متحفظة عمدًا
- أُضيف إلى الملفات حقل also بـ 19 إجابة صحيحة لم تكن مسجلة، دون تغيير الإجابات الأصلية (reports/gold_also.md)

ما جرّبناه لفهم السياق ولم يبلغ المستوى المطلوب

الهدف دقة 90% في قائمة التدقيق؛ قسنا كل طريقة على الحالات نفسها قبل أي قرار

نموذج لغوي يحكم: هل الكلمة بمعنى المصطلح هنا؟



مقارنة الجملة بتعريف المصطلح

0.55 إلى 0.67

4 نماذج تضمين

AUC؛ و0.5 تعني الصدفة

مصنّف متعلم على سمات الكاشف

0.46 إلى 0.48

انحدار لوجستي وتعزيز تدرجي

AUC على نوع نص لم يتدرب عليه

قبول العبارات دون فحص السياق

%76.5

اختبار التغريدات

استدعاء، لكن الإنذارات الكاذبة 68%

الخلاصة

الإشارات الثابتة (متجهات الكلمات، ميل المجال) لا تفصل المعنى في الكلمات اليومية، والنماذج المحلية الصغيرة لم تكفِ. لذلك صار التصميم صريحًا: ما لا نثق به يُعرض للتدقيق بسببه، ولا يُطبَّق آليًّا.

التحديات وحدود التقييم

التحديات التقنية

- غموض العربية دون تشكيل: «عميل» وكيل أو زبون، «بورصة» سوق أو صرف
- في المعاجم كلمات عامة مسجلة مصطلحات (انتهاء ← انقضاء)
- الأسماء والاختصارات تشبه المصطلحات (CSE، Telecom)
- إدراج المصطلح يكسر المطابقة: «المودلز الكبيرة» ← «النموذج الكبيرة»
- خادم الإطلاق بلا كرت شاشة: لا نموذج لغوي وقت التحليل

حدود التقييم

- الأحكام من Claude؛ مراجعة بشرية مستقلة لـ 50 حكمًا جارية
- بعض ملفات الاختبار كتبها فريق المشروع، وليست نصوصًا منشورة
- بعض القواعد صُمّمت بعد قراءة دفعات المقالات التي قيست عليها؛ الأرقام النزيهة: دفعة حُكم عليها قبل أي تعديل (مقترح 8 من 8، تدقيق 62%)
- عينات «مقترح» في المقالات صغيرة (15 اقتراحًا)
- التغريدات اختبار قاسٍ متعمد، لا يمثل الاستعمال المتوقع

نموذج الشركة: يضبط صيغة الكلمة بعد إدراج المصطلح، لا أكثر

ما كتبه المستخدم
درّبنا المودلز الكبيرة على الداتا الجديدة

↓

بعد إدراج مصطلحات سوار
درّبنا النموذج الكبيرة على البيانات الجديدة

↓

بعد نموذج الشركة
درّبنا النماذج الكبيرة على البيانات الجديدة

الكاشف نفسه ينبّه اليوم: «وردت بصيغة الجمع، فراجع صيغة المصطلح بعد الاستبدال»؛ هذا ما يحلّه النموذج.

موقعه في البنية: بعد قرار المستخدم وقبل النص النهائي. المصطلح يبقى من سوار دائمًا، والنموذج لا يرى إلا الجملة والمصطلح الذي اختاره المستخدم.

يفعل

- ✓ يضبط الإفراد والجمع
- ✓ يضبط التذكير والتأنيث
- ✓ في الكلمة المستبدلة وما يطابقها فقط

لا يفعل

- ✗ لا يختار المصطلح
- ✗ لا يعيد صياغة النص
- ✗ لا يعمل قبل قرار المستخدم

الخطة القادمة

الآن

جارٍ

- فحص 1,041 رابطًا يوميًّا بجمل حقيقية من ويكيبيديا، وسحب الخاطئ بعد المراجعة
- مراجعة بشرية مستقلة لـ 50 حكمًا

قبل الإطلاق

قريب

- نشر النسخة الأخيرة على kass.arai.center
- دمج فرع enrichment-pass1 في main

التالي

مخطط

- ربط نموذج الشركة لضبط الإفراد والجمع والتذكير والتأنيث
- قياسه على جمل حقيقية قبل اعتماده

لاحقًا

بحث

- إثراء «وكيل» و67 مصطلحًا بلا اسم إنجليزي
- حكم سياق خفيف يعمل على المعالج لرفع قائمة التدقيق نحو 90%

الطبقة تعرف ما يجب أن يُكتب (المصطلح المعتمد)، والمستخدم يقرر، ونموذج الشركة يضبط الصيغة.