مجمع الملك سلمان العالمي للغة العربية
King Salman Global Academy for Arabic Language

طبقة «خصص» لتوحيد المصطلحات في النصوص العربية

سارة عبدالله المبرد | تدريب تعاوني | مجمع الملك سلمان العالمي للغة العربية | ١٧ جمادى الأولى ١٤٤٨ هـ

مقدمة

يكتب غير المتخصصين التقارير والمقالات العربية بألفاظ متفرقة للمفهوم الواحد: كلمات أجنبية بحروف عربية («المودل»، «الداتا»)، أو عامية، أو كلمات عربية عامة في موضع المصطلح التخصصي («عميل» بدل «وكيل» في الذكاء الاصطناعي). ويؤدي ذلك إلى تفاوت المصطلحات بين النصوص، مع أن للمجمع معاجم متخصصة معتمدة على منصة «سِوار» تحدد المصطلح القياسي لكل مفهوم.

ويهدف المشروع إلى بناء طبقة تخصيصية تستبدل في الفقرة المصطلحات التي تحتاج إلى استبدال فقط، وتحوّلها إلى المصطلح المعتمد في معاجم المجمع، دون أن تمس بقية النص.

مثال: «المودل عندي حقق نتائج عالية» ← «النموذج عندي حقق نتائج عالية».

فكرة المشروع

يكتب المستخدم النص ويختار مجاله (قانوني، تقني، مالي وإداري، إعلامي، هندسي، علمي وثقافي)، ثم تحلل الطبقة النص وتعرض لكل كلمة مقترحة المصطلح المعتمد وتعريفه ومعجمه، ويختار المستخدم ما يستبدله. والمنتج النهائي طبقة قابلة للإضافة إلى أي منصة كتابة، مثل «سليم» أو أدوات الترجمة. وتمر مراحل العمل بالترتيب الآتي: استخراج المعاجم، ثم إثراؤها بالصيغ البديلة، ثم التمثيل الدلالي، ثم الكشف واتخاذ القرار، ثم التعديل اللغوي الأدنى.

ما أُنجز حتى الآن

- **استخراج المعاجم:** اكتمل استخراج ٢٢ معجمًا من منصة سِوار، تضم ٣٧,١٢٤ مدخلًا و٤٠,١٠٢ معنى، في مجالات منها الطيران والفضاء والقانون والعقود والمالية والطاقة والبيانات والذكاء الاصطناعي. وتلتزم أداة الاستخراج بملف robots.txt للمنصة (فاصل خمس ثوانٍ بين الطلبات)، وتحفظ تقدمها كل ٢٥ مدخلًا، وتستأنف من آخر نقطة بعد أي انقطاع، ولم تُعدَّل ملفات المصطلحات الأصلية.
- **الإثراء الأول:** أُضيفت لكل معنى الصيغ التي يكتبها الناس بدلًا من المصطلح القياسي؛ صاغ نموذج Qwen3.5-4B مسودات الصيغ، وراجعها Claude وصححها وأكملها. وبلغت ٨٢,٢٠٤ صيغة: ٦١,٤٩٨ صيغة إنجليزية، و١٠,٢٨٤ مرادفًا عربيًا غير رسمي، و٥,٦٨٤ اختصارًا، و٢,٦٢٤ كتابة صوتية بالحروف العربية، و١,٣٤٥ صيغة عامية، و٧٦٧ اختلافًا إملائيًا.
- **الإثراء العربي الثاني:** تبيّن أن الصيغ العربية قليلة مقارنة بالإنجليزية، فبُنيت أداة إضافة لا تحذف شيئًا. وفشل نموذج Qwen3.5-4B في هذه المهمة لاختراعه صيغًا غير مستعملة، وفشل نموذج Gemma حين عمل حَكَمًا منفردًا (قبِل «فرصة» مرادفًا لـ«احتمال»). فاعتُمد أن يقترح نموذج Gemma 3 12B على جهاز المكتب ويراجع Claude الاقتراحات، ضمن تشغيل آلي كل نصف ساعة. واكتملت الجولة لجميع المعاني (٤٠,١٠٢)، وأُضيفت ٥,٥٦٨ صيغة عربية، منها «سكليف» للإجازة المرضية و«بارامتر» للمعامل.
- **إضافات يدوية حسب الموضوع:** روجع ١,١٢٨ مصطلحًا من أكثر المصطلحات استعمالًا في المعاجم، وأُضيفت نحو ٧٠ صيغة عامة ناقصة، مثل «غلاء الأسعار» للتضخم، و«مرتكب الجريمة» للجاني، و«هندسة المطالبات» لهندسة الأوامر. ويبلغ مجموع الصيغ الآن ٨٧,٧٨٤ صيغة، منها ٥٠,٥٩٥ مقبولة و٣٧,١٨٩ تحتاج تدقيقًا لأنها مشتركة بين أكثر من مصطلح، فلا تُستبدل تلقائيًا.

- **التمثيل الدلالي:** حُوّلت ١٢٢,٣٠٦ نصوص (٤٠,١٠٢ مصطلح مع تعريفه، والصيغ المضافة) إلى متجهات بنموذج EmbeddingGemma-300m من Google، وهو نموذج مفتوح ومجاني بنحو ٣٠٨ ملايين معامل، يعطي لكل نص متجهًا من ٧٦٨ بُعدًا. وبلغت السرعة نحو ٧٠ نصًا في الثانية على جهاز Mac.
- **مدونة مرجعية من المقالات:** جُمع ٣,٥٤٤ مقالًا من ويكيبيديا العربية: ٥٠٠ مقال لكل مجال، ونحو ١,٥٠٠ مقال عام للمقارنة. ومنها حُسب لـ٣٦,٩٥١ كلمة مدى ارتباطها بكل مجال، وبصمة معنى لكل كلمة.
- **المحلل:** بُني محلل يكتشف المصطلحات بمطابقة القاموس مع فصل السوابق واللواحق («والمودلز» ← «مودل»)، وبالمطابقة الصوتية مع الإنجليزية («بروسسينق» ← processing)، وبقراءة الاختصارات («الكي بي آي» ← KPI). ويختار المعنى المناسب بقرب المعنى من سياق الجملة، فيقترح للكلمات العربية العامة مصطلحها التخصصي فقط حين يكون سياق النص من المجال المختار. ولا يعمل أي نموذج وقت التحليل، فالمتجهات محسوبة مسبقًا.
- **تجربة نموذج حَكَم:** اختُبر Gemma 3 12B حكمًا يقرر الاستبدال (بديلًا من نموذج Jev الذي لم يُحدَّد بعد) على ٦٠٠ حالة، فبلغت دقته ٦٦٪، والإحكام ٦١,٥٪، والاستدعاء ٨٥,٣٪، ولم تكن درجة ثقته مفيدة في التمييز، فلم يُعتمد.
- **صفحة التجربة والواجهة البرمجية:** بُنيت صفحة تجربة بشعار المجمع، وكُتبت واجهة برمجية (API) بلغة Python. ونتائجهما متطابقة في جميع جمل الاختبار (٢١٢ جملة)، وتستهلك الواجهة نحو ٢٠٠ ميغابايت من الذاكرة، وتحلل الجملة في أجزاء من الثانية.
- **النشر على خادم المجمع:** جُهّز المشروع في حاوية Docker واحدة تقدم صفحة التجربة والواجهة البرمجية معًا، وتعمل على المعالج دون بطاقة رسومية ودون أي نموذج وقت الاستخدام. وبُنيت الحاوية على خادم المجمع نفسه بأداة podman المتبعة في بقية تطبيقاته، ووُصلت بخادم الويب المشترك، فأصبح المشروع متاحًا على الرابط kass.arai.center، ووثائق الواجهة البرمجية للمطورين على kass.arai.center/docs، دون المساس بالتطبيقات الأخرى على الخادم.
- **تحسينات صفحة التجربة:** نُقل شعار المجمع إلى أعلى اليمين واسم «خصص» إلى أعلى اليسار، وأصبح مربع الكتابة فارغًا مع ثلاثة أمثلة تحوّل كلمات عربية عامة إلى مصطلحاتها التخصصية (التقني والقانوني والإعلامي). وأضيف زر لمسح النص، وأصبحت كل كلمة مقترحة تفتح قائمة منسدلة يختار منها المستخدم المصطلح المقترح ومعجمه أو يبقي كلمته الأصلية، حتى لو كان المقترح مصطلحًا واحدًا. كما أضيف الوضعان الداكن والفاتح بألوان الموقع، وصُغّر الخط، وهُيئت الصفحة للجوالات.
- **أداة تدقيق الصيغ:** أضيف إلى أداة الإثراء خيار يحذف أي صيغة خاطئة من أي جولة إثراء، مع تسجيل المحذوف في سجل خاص دون حذف السجلات القديمة، وجُرّب تجربة جافة دون تغيير البيانات. وتبيّن أثناء التجربة أن الحكم يجب أن يكون في السياق: فـ«الحضور» مرادف صحيح لـ«المواظبة»، والخطأ كان في جملة «بحضور المحامي» وحدها.

النتائج

كُتبت مجموعات اختبار من جمل يكتبها غير المتخصصين، وقيس عليها المحلل. و«الاستدعاء» نسبة ما اكتشفه من المصطلحات المطلوبة، و«الإحكام» نسبة الصحيح مما اقترحه.

مجموعة الاختبار	عدد الجمل	الاستدعاء	الإحكام
جمل الضبط (كلمات دخيلة وعامية)	٤٦	٩٣,٨٪	٨٦,٥٪
جمل مخفية لم يُضبط عليها (١)	٣٠	٨١,٠٪	٦٣,٠٪
جمل مخفية لم يُضبط عليها (٢)	٢٤	٩٤,٧٪	١٠٠٪
كلمات متعددة المعاني	١٤	٧١,٤٪	٥٨,٨٪
كلمات عربية عامة (جمل مخفية)	٢٨	٨٣,٣٪	٥٠,٠٪

وارتفعت نسبة الاستبدال التلقائي الصحيح من ٧٧٪ إلى ٨٦٪ بعد إضافة السياق. وبعض ما يُحسب خطأً مرادفات مقبولة لم تتوقعها جمل الاختبار، مثل «القضية» ← «الدعوى».

عينة من البيانات

تعرض العينة أدناه أمثلة من تحليل المحلل لجمل الاختبار، وطريقة اكتشاف كل كلمة.

النص	الكلمة	طريقة الكشف	المصطلح المعتمد	الحالة
المودل عندي حقق نتائج عالية	المودل	صيغة من الإثراء	النموذج	استبدال مقترح
الشركة تسوي بروسسينق للبيانات الشخصية	بروسسينق	مطابقة صوتية مع processing	المعالجة	استبدال مقترح
الجندي ركّب الفيوز في القذيفة	الفيوز	اختيار المعنى من السياق	فتيلة انفجار	استبدال مقترح
بنينا عميل ذكي يرد على المستخدمين	عميل ذكي	كلمة عامة في سياق تقني	وكيل ذكي	يحتاج اختيارًا
قدم المدعي القضية إلى المحكمة	القضية	كلمة عامة في سياق قانوني	الدعوى	يحتاج اختيارًا
مقدم البرنامج استضاف وزير الإعلام	مقدم	كلمة عامة في سياق إعلامي	مذيع	يحتاج اختيارًا
نحرص على رضا العميل	العميل	سياق غير تخصصي	—	تبقى كما هي

في المجال التقني لأمثلة الذكاء الاصطناعي، والقانوني لمثالي المعالجة والدعوى، والإعلامي لمثال المذيع، والهندسي لمثال الفيوز.

الخطوات القادمة

- جولة إثراء ثالثة على جهاز المكتب، يقترح فيها Gemma 3 12B الكلمة العربية العامة المقابلة لكل مصطلح، ثم تُراجع الاقتراحات قبل إضافتها.
- تدقيق نحو ١١ ألف رابط ضعيف من الإثراء الأول بين كلمات عامة ومصطلحات (مثل «بحضور» ← «المواظبة»)، وحذف الخاطئ منها بأداة التدقيق الجاهزة، لأنها السبب الرئيسي للأخطاء المتبقية.
- بناء مرحلة التعديل اللغوي الأدنى، التي تطابق المصطلح المستبدل مع الجملة في الإفراد والجمع والتذكير والتأنيث، واختيار نموذجها بعد التجربة.
- التقييم على فقرات حقيقية من تقارير ومقالات، وتحديث النسخة المنشورة على خادم المجمع بعد كل تحسين في البيانات.

خاتمة

اكتملت مراحل الاستخراج والإثراء والتمثيل الدلالي، وبُني محلل يعمل دون نموذج وقت التحليل، مع صفحة تجربة وواجهة برمجية متطابقتين، ونُشر المشروع على خادم المجمع في الرابط kass.arai.center. وتركز المرحلة القادمة على تحسين جودة البيانات بالتدقيق والإثراء الثالث، ثم بناء التعديل اللغوي الأدنى وتقييم الطبقة على نصوص حقيقية.ے